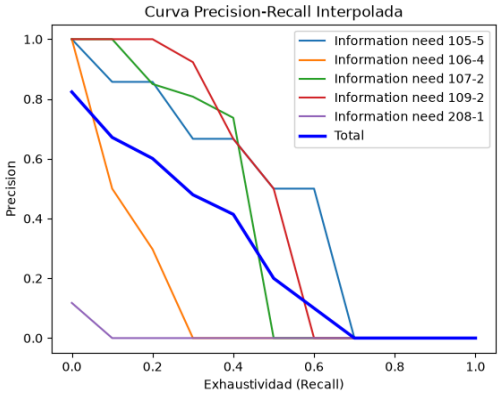
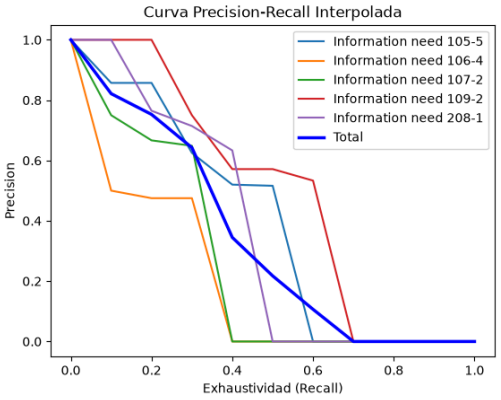
Alumnos: Ciro Fustero Zumeta (NIP: 900506) y Hector Esteban Ortiz (NIP: 898030)

INFORME PRACTICA 3

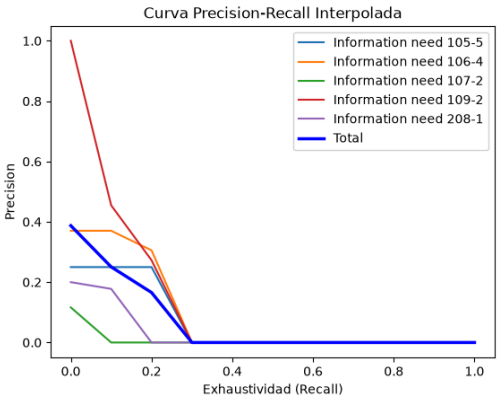
Capacidad del programa los sistemas a y b

Una vez hecho el evaluador, lo pusimos a prueba con los ficheros a y b proporcionados, en ambos casos los resultados de las métricas totales eran los esperados:

Sistema A	Sistema B
precision 0.378 recall 0.375 F1 0.376 prec@10 0.640 MAP 0.591 interpolated_recall_precision 0.000 0.824 0.100 0.671 0.200 0.601 0.300 0.479 0.400 0.414 0.500 0.200 0.600 0.100 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	precision 0.489 recall 0.484 F1 0.486 prec@10 0.760 MAP 0.705 interpolated_recall_precision 0.000 1.000 0.100 0.821 0.200 0.753 0.300 0.643 0.400 0.345 0.500 0.218 0.600 0.107 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000
	

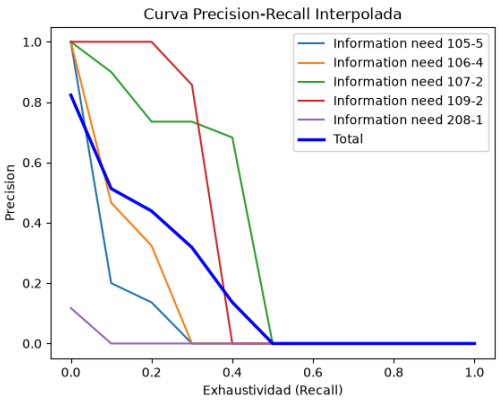
Comparación de nuestro sistema frente a y b

Después usamos el evaluador con nuestro sistema de la p2, y nos dimos cuenta de lo malo que era frente a A y B (todas nuestras métricas son peores que A):

precision 0.187 recall 0.193 F1 0.190 prec@10 0.160 MAP 0.222 interpolated_recall_precision 0.000 0.387 0.100 0.251 0.200 0.166 0.300 0.000 0.400 0.000 0.500 0.000 0.600 0.000 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	

Comparación de nuestro sistema frente al de la P1

Probando con Gemsin, nos dimos cuenta de que era bastante mejor que nuestro sistema, pero también peor en todas las métricas que A y B:

precision 0.298 recall 0.269 F1 0.283 prec@10 0.520 MAP 0.555 interpolated_recall_precision 0.000 0.824 0.100 0.513 0.200 0.439 0.300 0.318 0.400 0.137 0.500 0.000 0.600 0.000 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	

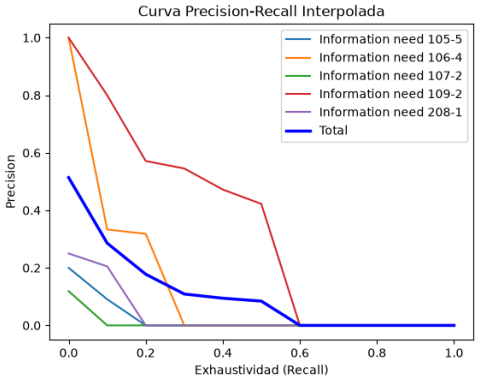
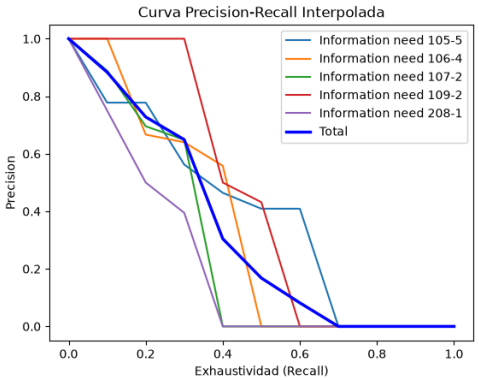
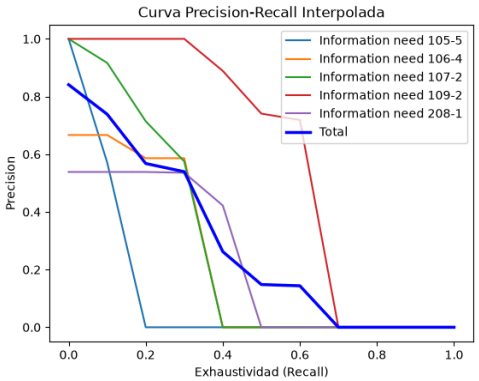
Reflexión sobre las mejores medidas

Si nos da igual el orden de los ficheros devueltos, la mejor métrica sería el F1, ya que tiene en cuenta tanto la precisión como el recall, es decir, mide la precisión de nuestro sistema teniendo en cuenta cuántos documentos relevantes nos dejamos. Si importara el orden de los documentos, la mejor métrica sería el MAP, ya que también mira que los documentos relevantes aparezcan antes.

Justificación las medidas obtenidas

Tras haber analizado los resultados detenidamente, nos dimos cuenta de que la razón de que los resultados sean tan pésimos es que estábamos utilizando el modelo de TFIDF sin asignar pesos diferentes a los campos más relevantes, lo cual hacía que si aparece 8 veces la misma palabra, le dará 8 veces más importancia. Ante esto probamos 3 estrategias, la

primera de ellas fue asignar un peso doble a los campos que considerábamos más relevantes, que eran aquellos que Spacy identificaba como persona, organización o localización. La segunda fue cambiar tfidf por BM25F sin usar pesos, y la última fue combinar las 2.

Usando TFIDF con pesos	precision 0.227 recall 0.232 F1 0.229 prec@10 0.220 MAP 0.270 interpolated_recall_precision 0.000 0.514 0.100 0.286 0.200 0.178 0.300 0.109 0.400 0.094 0.500 0.084 0.600 0.000 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	
Usando BM25F	precision 0.458 recall 0.453 F1 0.455 prec@10 0.760 MAP 0.695 interpolated_recall_precision 0.000 1.000 0.100 0.883 0.200 0.728 0.300 0.649 0.400 0.304 0.500 0.168 0.600 0.082 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	
Usando BM25F con pesos	precision 0.409 recall 0.389 F1 0.398 prec@10 0.660 MAP 0.666 interpolated_recall_precision 0.000 0.841 0.100 0.739 0.200 0.568 0.300 0.539 0.400 0.262 0.500 0.148 0.600 0.144 0.700 0.000 0.800 0.000 0.900 0.000 1.000 0.000	

Como podemos ver, los pesos mejoran mucho el modelo que usa TFIDF, pero empeoran el que usa BM25F. Así que decidimos quedarnos con el modelo que solo usa BM25F.
Si comparamos el modelo final (BM25F) frente a B (el mejor de los 2 sistemas proporcionados), se puede observar que es solamente un poco peor (tiene menos F1 y

MAP), pero tienen la misma prec@10, es decir, logran recuperar exactamente la misma cantidad de documentos relevantes dentro del top 10.