Alumnos: Ciro Fustero Zumeta (NIP: 900506) y Hector Esteban Ortiz (NIP: 898030)

INFORME PRACTICA 1

Proceso seguido para la indexación

Para la indexación hemos definido los siguientes campos para la indexación:

- identifier: Hace referencia al identificador del documento que buscamos y lo usamos únicamente para representar los documentos cuando usamos la opción -output.
- creator: Hace referencia al autor del documento que buscamos.
- contributor: Hace referencia al director a cargo del documento que buscamos.
- publisher: Hace referencia al departamento donde se publicó el documento que buscamos.
- date: Hace referencia al año cuando se publicó el documento que buscamos.
- title: Hace referencia al título del documento que buscamos.
- subject: Hace referencia a la materia del documento que buscamos.
- description: Hace referencia a la descripción del documento que buscamos.
- Además se usan ya los campos definidos desde un inicio: path (ruta del archivo), content (texto completo para ficheros .txt) y modtime (fecha física de modificación).

El sistema itera sobre el directorio procesando los ficheros de Zaguan (todos son xml) utilizando la librería ElementTree para parsear el árbol. Se recorren todas las etiquetas, guardando los valores de cada etiqueta correspondientes con los campos mencionados anteriormente (title, creator, etc) en listas separadas por campo. Esto permite buscar documentos que tengan más de un valor en uno de esos campos (por ejemplo, si hay 2 autores).

Pruebas realizadas

Decidimos llevar a cabo una breve serie de pruebas para demostrar la funcionalidad de nuestro indexador y buscador. Las más destacables se detallan a continuación:

creator:Pilar
creator:Pilar AND publisher:derecho
creator:Pilar AND title:derecho
creator:Pilar AND contributor:Pablo AND publisher:Psicología
creator:Pilar AND contributor:Pablo AND description:niños
creator:Pilar AND contributor:Pablo AND description:niños AND publisher:Psicología AND date:2020 AND subject:educación AND title:académico

La primera prueba es la más básica, sirve para poner a prueba la capacidad de buscar por campos y a su vez para asegurarnos de que el límite de 100 resultados está operativo (ya que una búsqueda tan inespecífica devuelve alrededor de 300 resultados). Para ambos objetivos los resultados son satisfactorios.

La segunda y tercera prueba sirven para asegurar que no está buscando en todos los campos, y que solo está buscando “derecho” en publisher y en title en cada uno de ellos. La consulta 2 obtiene 30 resultados y la 3 solo 6, de los cuales 2 no son en común con la 2. Tras comprobarlo manualmente, pudimos ver que en efecto esos 2 son los únicos que no tienen derecho en el título y en director a la vez. En uno de ellos la palabra “derecho” no hace referencia a ciencias jurídicas, sino a un músculo situado en la zona derecha del cuerpo, por lo que el departamento al que pertenece no es el de derecho y como tal no aparece en publisher. Mientras que el otro la palabra que encuentra en el título es “derecha” haciendo referencia al lado conservador de la política y por lo tanto no pertenece al departamento de ciencias jurídicas.

La cuarta y quinta están destinadas a probar la funcionalidad del buscador ante la presencia de caracteres especiales como vocales acentuadas o la ñ. Ambos casos fueron creados a partir del mismo documento (http://zaguan.unizar.es/record/95290) y ambos fallaban inicialmente porque se corrompían los carácteres al pasarlos desde el documento txt, así que fué necesario cambiar el código en el search poniendo “encoding=utf-8” al open. Una vez se corrigió este error funcionaba perfectamente. La cuarta consulta devuelve 2 archivos (ambos correctos, pero debido a que Zaguan no permite buscar por director no pudimos comprobar si se dejó alguno). Mientras que la quinta solo devuelve un resultado (aquel del que sacamos los ejemplos en primer lugar).

Por último, el propósito de la sexta es demostrar que todos los campos funcionan al hacer una búsqueda con todos los campos que sabemos que devolverá al menos un resultado, si alguno de ellos no se hubiese registrado correctamente, no devolverá nada, pero como el resultado es el mismo que en la sexta consulta, funciona perfectamente.